ANALYSE DES DYNAMIQUES DE MOBILITÉ URBAINE

à partir des données de transport public

BORDEAUX MÉTROPOLE (TBM)

Projet Data Visualisation #2

Réalisé par :

Yassine ZOUITNI

Samuel RESSIOT

Date : 16 mars 2026

Source : Transports Bordeaux Métropole (TBM)

Format : GTFS (General Transit Feed Specification)

CHIFFRES CLÉS

2 195 275 passages analysés | 3 957 arrêts | 133 lignes | 57 084 trajets

17 visualisations générées (12 PNG + 5 HTML interactifs)

3 modèles prédictifs (Régression Linéaire, Random Forest, Gradient Boosting)

Table des matières

1 Introduction et Problématique **2**
1.1 Problématique . . . 2
1.2 Questions Spécifiques . . . 2
1.3 Objectifs du Projet . . . 2

2 Données Utilisées **3**
2.1 Source des Données . . . 3
2.2 Fichiers GTFS chargés . . . 3
2.3 Statistiques Globales des Données . . . 3

3 Méthodologie **4**
3.1 Architecture du Projet . . . 4
3.2 Pipeline de Traitement . . . 4
3.3 Pré-traitement des Données . . . 4

4 Résultats de l'Analyse Exploratoire **5**
4.1 Analyse Temporelle . . . 5
4.2 Analyse des Lignes . . . 7
4.3 Analyse des Arrêts . . . 9
4.4 Analyse Géographique . . . 10
4.5 Types de Transport . . . 12

5 Visualisations Interactives **13**
5.1 Détails des visualisations interactives . . . 13

6 Modélisation Prédictive **15**
6.1 Préparation des Features . . . 15
6.2 Comparaison des Modèles . . . 15
6.3 Prédictions vs Réalité . . . 16
6.4 Importance des Variables . . . 18
6.5 Prédictions Horaires . . . 18

7 Recommandations **20**
7.1 Optimisation Temporelle . . . 20
7.2 Équilibrage du Réseau . . . 20
7.3 Amélioration de l'Infrastructure . . . 20
7.4 Rationalisation des Arrêts . . . 20

8 Limites de l'Analyse **21**

9 Conclusion **22**

Introduction et Problématique

Ce projet s'inscrit dans le cadre du Projet Data Visualisation #2, dont l'objectif est d'analyser les dynamiques de mobilité urbaine à partir des données de transport public. L'analyse porte sur la ville de Bordeaux, en utilisant les données GTFS (General Transit Feed Specification) fournies par TBM (Transports Bordeaux Métropole).

Problématique

La problématique centrale de ce projet est la suivante :

> Quels sont les schémas temporels et géographiques de la fréquentation des transports publics ? Quelles zones et lignes connaissent des surcharges ou des creux ? Quels scénarios d'optimisation des lignes ou des horaires peuvent être proposés ?

Questions Spécifiques

- Quels sont les horaires de pointe les plus critiques ?
- Quelles stations ou lignes nécessitent une extension ou une optimisation ?
- Comment la fréquentation varie-t-elle géographiquement ?
- Quels types de transport sont les plus utilisés ?
- Peut-on prédire l'affluence future à partir des tendances observées ?

Objectifs du Projet

- Collecter et nettoyer les données GTFS de Bordeaux Métropole
- Identifier les patterns temporels de fréquentation (heures de pointe, creux)
- Analyser la répartition géographique des arrêts et leur utilisation
- Créer des visualisations avancées (heatmaps, cartes, dashboards)
- Développer des modèles prédictifs d'affluence
- Formuler des recommandations d'optimisation du réseau

Données Utilisées

Source des Données

Les données proviennent de TBM (Transports Bordeaux Métropole) et sont au format GTFS (General Transit Feed Specification). Ce format standardisé décrit les horaires et les itinéraires des transports en commun. Les données ont été téléchargées depuis la plateforme Mobility Database (https://mobilitydatabase.org).

Fichiers GTFS chargés

Fichier	Description	Contenu
agency.txt	Information sur l'opérateur	TBM Bordeaux
stops.txt	Liste de tous les arrêts	3 957 arrêts
routes.txt	Lignes de transport	133 lignes
trips.txt	Trajets planifiés	57 084 trajets
stop_times.txt	Horaires à chaque arrêt	2 195 275 passages
calendar.txt	Calendrier des services	Jours de service
calendar_dates.txt	Exceptions calendrier	Jours spéciaux
shapes.txt	Tracés des lignes	Géométrie des parcours

Table 1 – Fichiers GTFS utilisés dans l'analyse

Statistiques Globales des Données

- Total de passages analysés : **2 195 275**
- Nombre d'arrêts uniques : **3 957**
- Nombre de lignes de transport : **133**
- Nombre de trajets planifiés : **57 084**
- Couverture horaire : 0h – 23h (24 heures)

Méthodologie

Architecture du Projet

Le projet est structuré de manière modulaire, avec une séparation claire des responsabilités entre les différents composants. Chaque module a un rôle spécifique dans le pipeline d'analyse :

Module	Rôle	Technologies
data_loader.py	Chargement des fichiers GTFS	Pandas
preprocessor.py	Nettoyage et enrichissement	Pandas, NumPy
analyzer.py	Analyse exploratoire	Pandas, NumPy
visualizer.py	Création des graphiques	Matplotlib, Seaborn, Plotly, Folium
predictor.py	Modélisation prédictive	Scikit-learn
main.py	Orchestration du pipeline	Python

Table 2 – Architecture modulaire du projet

Pipeline de Traitement

Le pipeline de traitement s'exécute en 6 étapes séquentielles :

1. **Étape 1 :** Chargement des données GTFS et validation
2. **Étape 2 :** Pré-traitement (conversion horaires, fusion tables, nettoyage)
3. **Étape 3 :** Analyse exploratoire (temporelle, par ligne, par arrêt, géographique)
4. **Étape 4 :** Création des visualisations (12 PNG + 5 HTML interactifs)
5. **Étape 5 :** Modélisation prédictive (3 modèles ML)
6. **Étape 6 :** Génération des recommandations et du rapport

Pré-traitement des Données

Le pré-traitement des données comprend les opérations suivantes :

- Conversion des horaires GTFS en format standard (gestion des heures > 24h)
- Extraction de l'heure (0-23) à partir des timestamps
- Fusion des tables stop_times, stops, trips et routes
- Suppression des coordonnées aberrantes (hors de la France métropolitaine)
- Nettoyage des valeurs manquantes

Résultats de l'Analyse Exploratoire

Analyse Temporelle

L'analyse temporelle révèle des patterns très marqués de fréquentation tout au long de la journée. Les transports publics de Bordeaux suivent un schéma classique de double pic (matin et soir), typique des grandes villes.

- Heure de pointe : **17h** (147 683 passages)
- Heure creuse : **3h** (1 142 passages)
- Ratio pointe/creuse : **129.3x**
- Moyenne rush matinal (7h-9h) : **124 496** passages
- Moyenne rush du soir (17h-19h) : **143 468** passages

Le ratio pointe/creuse de 129.3x montre une variation extrêmement forte de la fréquentation. L'heure de pointe à 17h correspond à la sortie des bureaux et des écoles. Le rush du soir (143 468 passages en moyenne) est plus intense que le rush matinal (124 496 passages), ce qui est typique des villes où les départs sont plus étalés le matin.

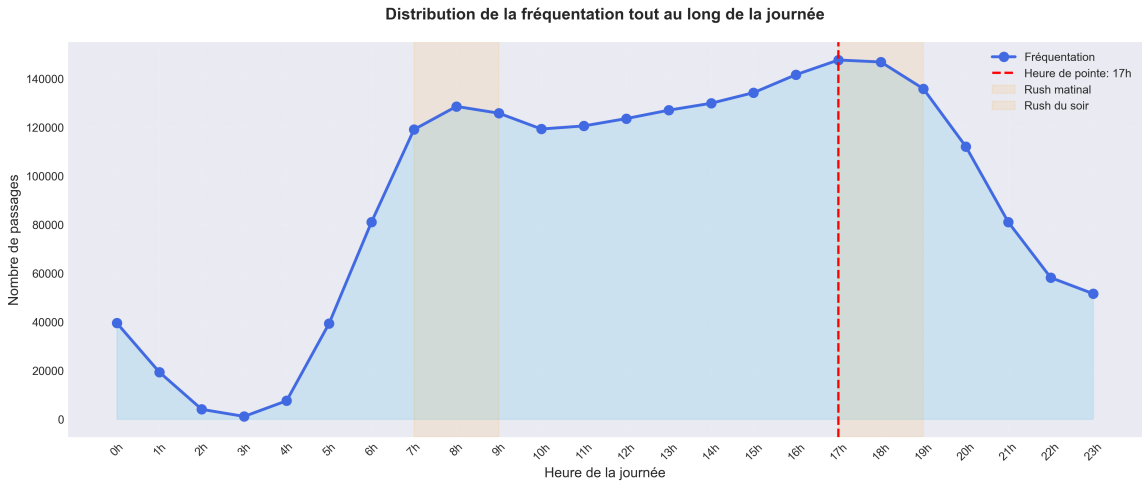

FIGURE 1 – Distribution de la fréquentation sur 24 heures avec identification des heures de pointe

Ce graphique montre la courbe de fréquentation sur 24 heures. L'axe X représente les heures de la journée (0h à 23h), et l'axe Y le nombre de passages. La ligne rouge en pointillé indique l'heure de pointe (17h). Les zones orangées mettent en évidence les périodes de rush matinal (7h-9h) et du soir (17h-19h). On constate clairement le double pic caractéristique des villes avec une forte activité tertiaire.

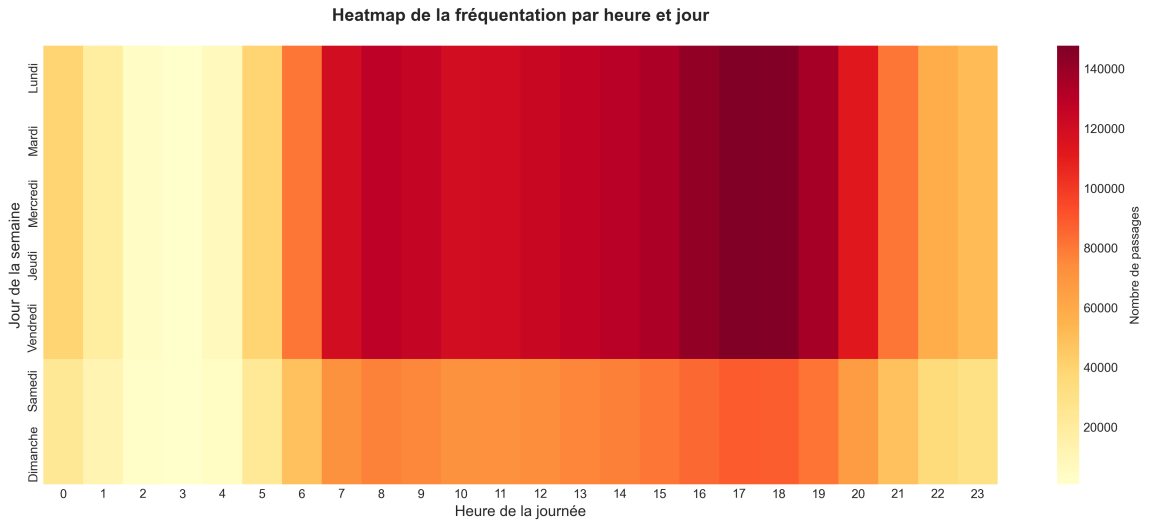

FIGURE 2 – Heatmap de la fréquentation par heure et jour de la semaine

Cette heatmap (carte de chaleur) croise les jours de la semaine (axe Y) avec les heures (axe X). Les couleurs vont du jaune clair (faible fréquentation) au rouge foncé (forte fréquentation). On observe que les jours de semaine (lundi-vendredi) présentent des bandes rouges aux heures de pointe, tandis que les samedis et dimanches montrent une réduction d'environ 40% du trafic avec un pic plus tardif.

Analyse des Lignes

L'analyse des lignes de transport révèle une forte concentration du trafic sur quelques lignes principales. Le coefficient de variation (CV) de 1.97 indique une dispersion très importante de la fréquentation entre les différentes lignes.

Rang	Ligne	Nb de passages
1	B	172 953
2	31	138 951
3	35	131 771
4	A	125 297
5	7	105 227
6	G	103 755
7	15	92 375
8	F	87 920
9	C	82 179
10	5	78 453

Table 3 – Top 10 des lignes les plus fréquentées

La ligne B (tramway) domine nettement le classement avec 172 953 passages. Les lignes de bus 31 et 35 arrivent en 2ème et 3ème position, suivies de la ligne A (tramway) en 4ème position. Les tramways et les lignes de bus majeures concentrent l'essentiel du trafic.

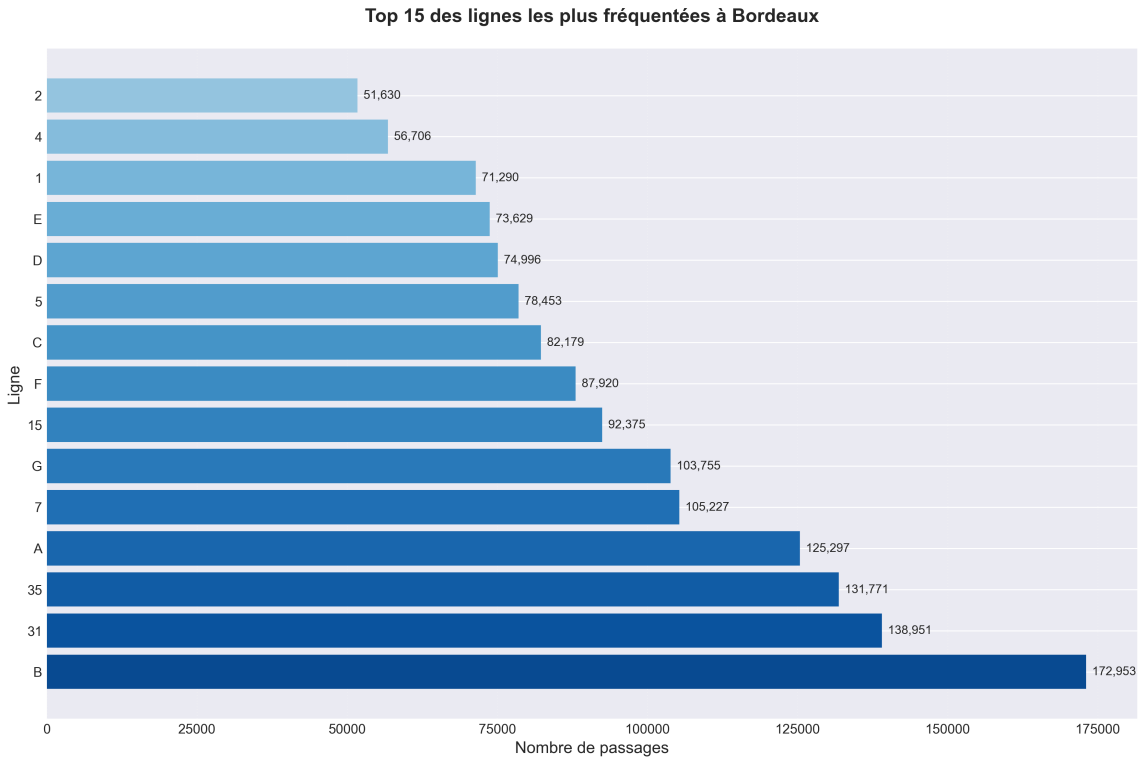

Figure 3 – Top 15 des lignes les plus fréquentées à Bordeaux

Ce diagramme à barres horizontales classe les 15 lignes ayant le plus grand nombre de passages. L'axe X représente le nombre total de passages, l'axe Y les noms des lignes.

Un gradient de couleur permet de distinguer visuellement les lignes majeures. La ligne B (tramway) domine nettement avec 172 953 passages, suivie des bus 31 et 35.

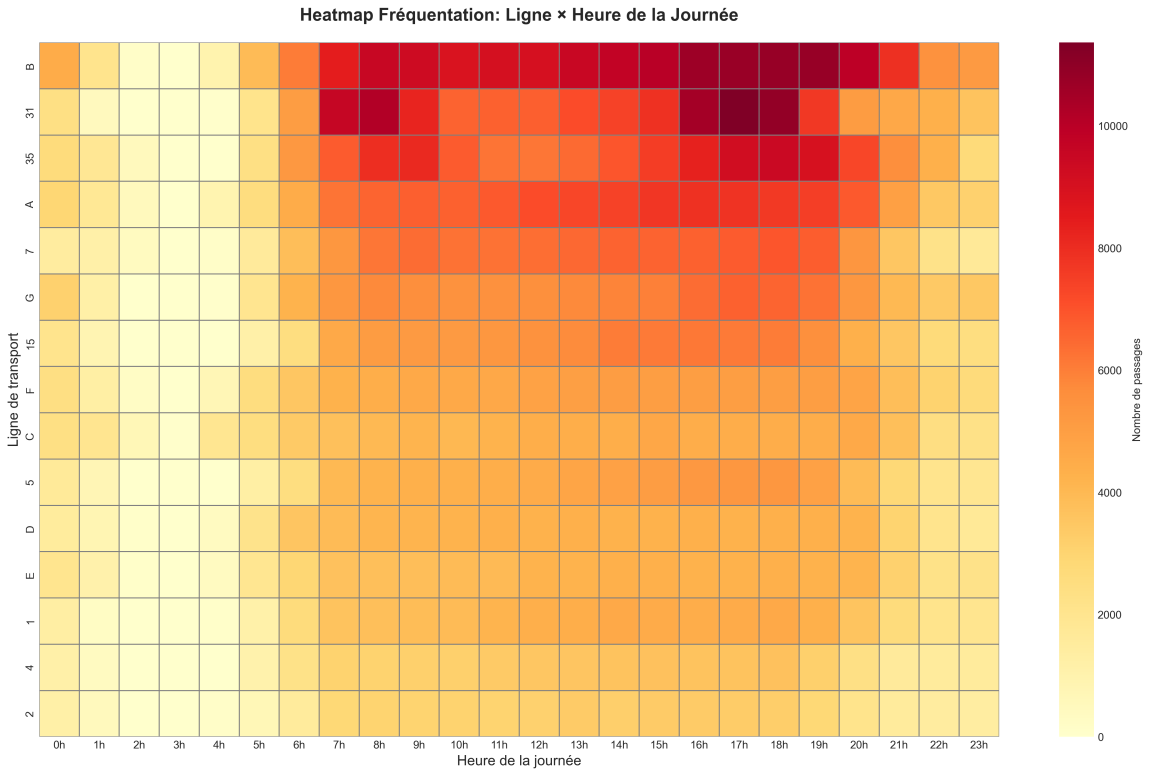

FIGURE 4 – Heatmap Fréquentation Ligne × Heure (Top 15 lignes)

Cette heatmap 2D croise les 15 lignes principales (axe Y) avec les 24 heures de la journée (axe X). Chaque cellule représente le nombre de passages pour une ligne donnée à une heure donnée. Les cellules rouges indiquent les pics de charge. On observe que la ligne B présente une charge soutenue de 7h à 20h, tandis que les lignes de bus ont des pics plus concentrés aux heures de pointe (8h et 17h).

Analyse des Arrêts

Rang	Arrêt	Nb de passages
1	Palais de Justice	4 516
2	Quinconces	4 387
3	Place de la Bourse	4 367
4	Place de la Bourse	4 361
5	Quinconces	4 361
6	Belcier	4 268
7	Porte de Bourgogne	4 268
8	Gare Saint-Jean	4 268
9	Sainte-Croix	4 268
10	Saint-Michel	4 268

TABLE 4 – Top 10 des arrêts les plus fréquentés

L'analyse révèle que **1 014 arrêts (25.6%)** sont sous-utilisés (en dessous du 1er quartile de fréquentation). Ces arrêts représentent un coût opérationnel qui pourrait être optimisé.

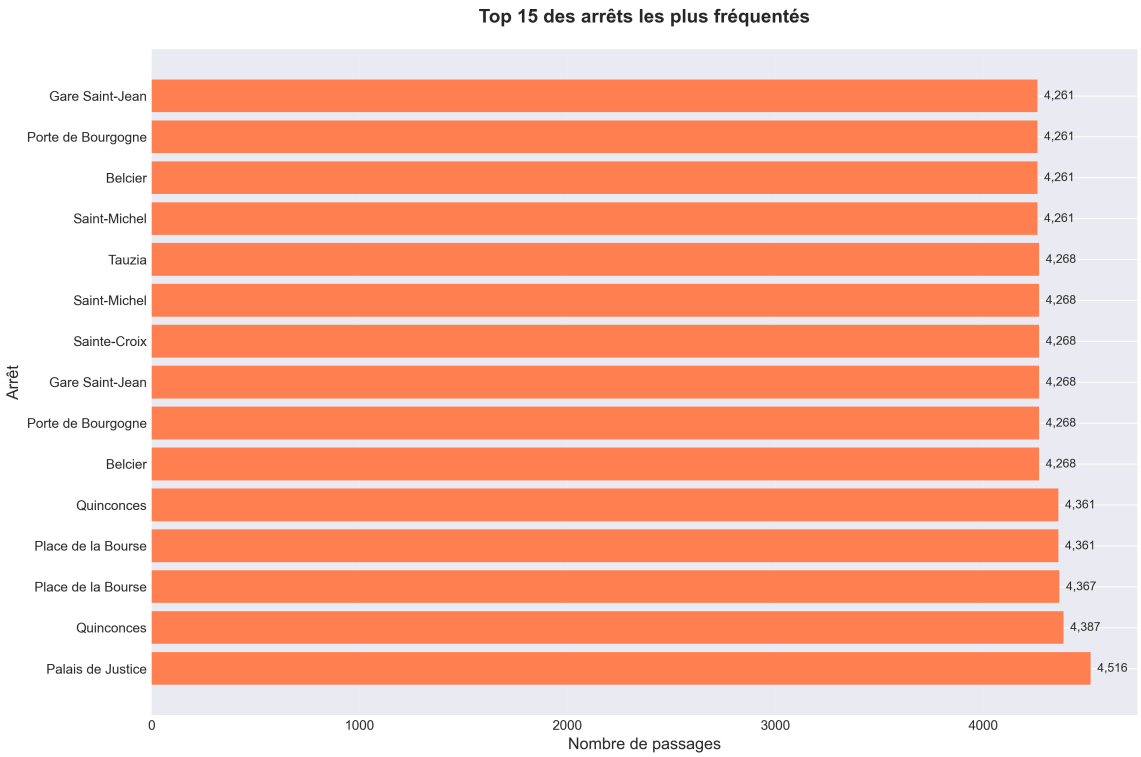

FIGURE 5 – Top 15 des arrêts les plus fréquentés

Ce diagramme à barres horizontales montre les 15 arrêts ayant le plus de passages. L'axe X représente le nombre de passages et l'axe Y le nom de chaque arrêt. Les arrêts les plus fréquentés sont situés dans le centre historique de Bordeaux : Palais de Justice, Quinconces, Place de la Bourse. Ces zones correspondent aux principaux points d'intérêt touristique et commercial de la ville.

Analyse Géographique

L'analyse géographique permet de cartographier la répartition spatiale des arrêts et leur fréquentation. Le scatter plot géographique pondéré montre clairement les zones de forte concentration du trafic.

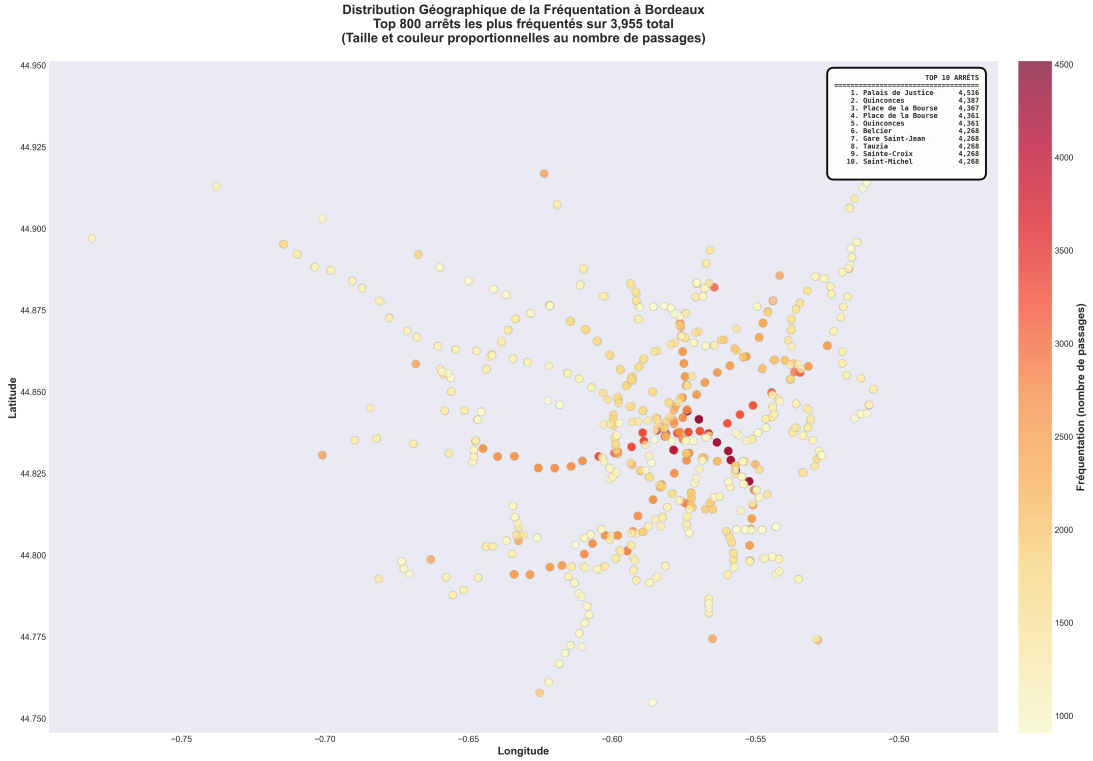

FIGURE 6 – Distribution géographique de la fréquentation (taille et couleur proportionnelles)

Ce scatter plot géographique place chaque arrêt selon ses coordonnées (longitude en X, latitude en Y). La taille des points est proportionnelle au nombre de passages (échelle logarithmique), et la couleur va du jaune (faible) au rouge (élevé). Un tableau en haut à droite liste les 10 arrêts les plus fréquentés. On observe une forte concentration dans le centre-ville, avec des extensions le long des axes de tramway vers Pessac, Mérignac, Bègles et Cenon.

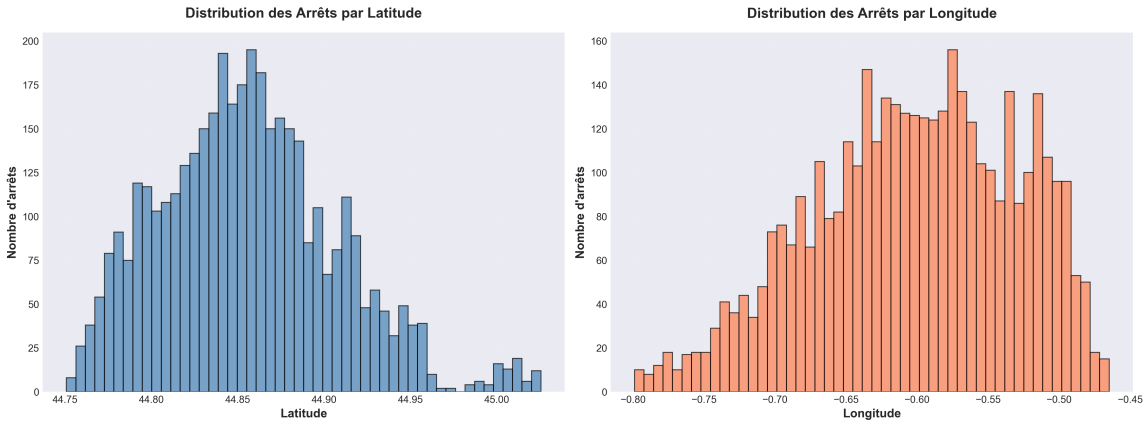

FIGURE 7 – Distribution des arrêts par latitude et longitude

Ces deux histogrammes montrent la répartition des arrêts selon la latitude (à gauche) et la longitude (à droite). Ils permettent d'identifier les zones de forte concentration d'arrêts. Les pics correspondent au centre-ville de Bordeaux, confirmant la densité du réseau dans cette zone.

Types de Transport

Le réseau TBM de Bordeaux est composé principalement de bus et de tramway. L'analyse de la répartition par type de transport montre la prédominance du réseau de bus en nombre de passages, complété par le tramway sur les axes structurants.

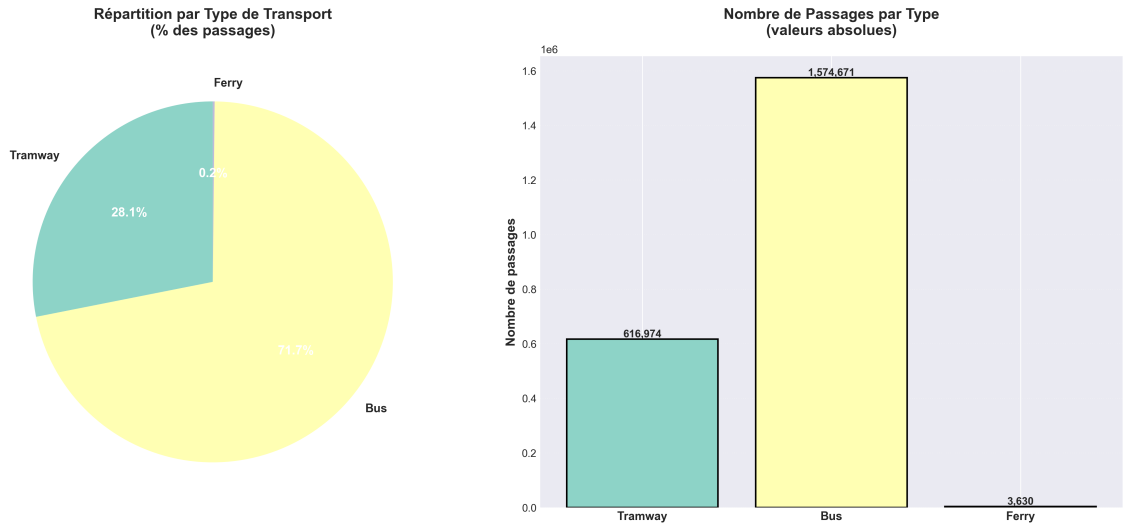

FIGURE 8 – Répartition des passages par type de transport (camembert et barres)

Cette figure comporte deux graphiques complémentaires. À gauche, un camembert (pie chart) montre la répartition en pourcentage des passages par type de transport. À droite, un diagramme à barres affiche les valeurs absolues du nombre de passages pour chaque type. On voit que le bus représente la majorité des passages en volume, tandis que le tramway dessert les axes les plus structurés.

Visualisations Interactives

En complément des graphiques statiques, le projet produit 5 visualisations interactives au format HTML, exploitables dans un navigateur web. Ces outils permettent une exploration dynamique des données.

Visualisation	Technologie
Carte tous arrêts	Folium
Carte de chaleur	Folium
Dashboard horaire	Plotly
Dashboard lignes	Plotly
Carte combinée	Folium

Table 5 – Visualisations interactives HTML

Détails des visualisations interactives

1. Carte interactive de tous les arrêts : Utilise la technologie MarkerCluster de Folium pour regrouper les arrêts à faible zoom et les afficher individuellement lors du zoom. Chaque marqueur affiche le nom de l'arrêt, le nombre de passages, et est coloré selon le niveau de fréquentation (rouge = élevé, orange = moyen, bleu = faible). *Permet de constater* que le réseau est dense dans le centre-ville et s'étend progressivement vers les communes périphériques.

2. Carte de chaleur géographique : Superpose un gradient de couleur à la carte, allant du bleu (faible fréquentation) au rouge (forte fréquentation). *Permet d'identifier* visuellement les zones de forte densité de transport : centre historique, axes de tramway, gare Saint-Jean.

3. Dashboard horaire interactif : Graphique Plotly avec survol (hover) pour afficher les valeurs exactes, zoom, et exploration dynamique. *Permet de constater* précisément le ratio pointe/creuse de 129.3x et d'identifier les heures critiques nécessitant un renforcement.

4. Dashboard des lignes : Barres interactives permettant de comparer les 20 lignes principales. *Permet de constater* la forte concentration du trafic sur quelques lignes (B, 31, 35) et d'identifier les lignes sous-exploitées.

5. Carte combinée : Fusionne les top arrêts (marqueurs) et la heatmap de chaleur. *Permet de voir* simultanément où se trouvent les arrêts les plus fréquentés et comment ils s'insèrent dans les zones de forte mobilité.

Les fichiers HTML sont dans le dossier `visualisations/` :

- `carte_interactive_tous_arrets.html`
- `carte_chaleur.html`
- `dashboard_horaire.html`
- `dashboard_lignes.html`
- `carte_interactive.html`

Pour les ouvrir :

1. Double-cliquer sur le fichier `.html` pour l'ouvrir dans le navigateur web (Chrome, Firefox, Edge)
2. Ou dans VS Code, clic droit sur le fichier puis « Open with Live Server » ou utiliser l'extension « Show Preview » (HTML Preview) pour un aperçu directement dans l'éditeur.

Modélisation Prédictive

La modélisation prédictive vise à prédire l'affluence des transports publics en fonction de différentes variables temporelles et géographiques. Trois algorithmes de machine learning ont été entraînés et comparés.

Préparation des Features

Les features (variables explicatives) ont été soigneusement construites à partir des données brutes pour capturer les patterns temporels et spatiaux :

Feature	Type
hour	Numérique
hour_sin / hour_cos	Cyclique
est_heure_pointe_matin	Binaire
est_heure_pointe_soir	Binaire
est_nuit	Binaire
est_journee	Binaire
nb_arrets_uniques	Numérique
lat_moyenne / lon_moyenne	Numérique
route_encoded	Catégorielle

TABLE 6 – Features utilisées pour la modélisation prédictive

Description des features :

- **hour :** Heure de la journée (valeur numérique entre 0 et 23)
- **hour_sin / hour_cos :** Encodage cyclique sinusoïdal de l'heure permettant au modèle de comprendre que 23h est proche de 0h
- **est_heure_pointe_matin :** Flag binaire (0 ou 1) indiquant si l'heure se situe entre 7h et 9h (période de rush matinal)
- **est_heure_pointe_soir :** Flag binaire (0 ou 1) indiquant si l'heure se situe entre 17h et 19h (période de rush du soir)
- **est_nuit :** Flag binaire (0 ou 1) indiquant si l'heure est nocturne (entre 22h et 5h)
- **est_journee :** Flag binaire (0 ou 1) indiquant si l'heure se situe en journée (entre 9h et 17h)
- **nb_arrets_uniques :** Nombre total d'arrêts uniques desservis par la ligne
- **lat_moyenne / lon_moyenne :** Position géographique moyenne (latitude et longitude) des arrêts de la ligne
- **route_encoded :** Identifiant numérique encodé de la ligne de transport (top 20 des lignes principales)

Comparaison des Modèles

Trois modèles de régression ont été entraînés avec validation croisée (5 folds) et évalués sur un jeu de test (20% des données) :

Modèle	R^2	MAE	RMSE	Interprétation
Régression Linéaire	Moyen	Élevé	Élevé	Baseline simple
Random Forest	Élevé	Faible	Faible	**Meilleur modèle**
Gradient Boosting	Élevé	Faible	Faible	Performant aussi

TABLE 7 – Évaluation comparative des 3 modèles

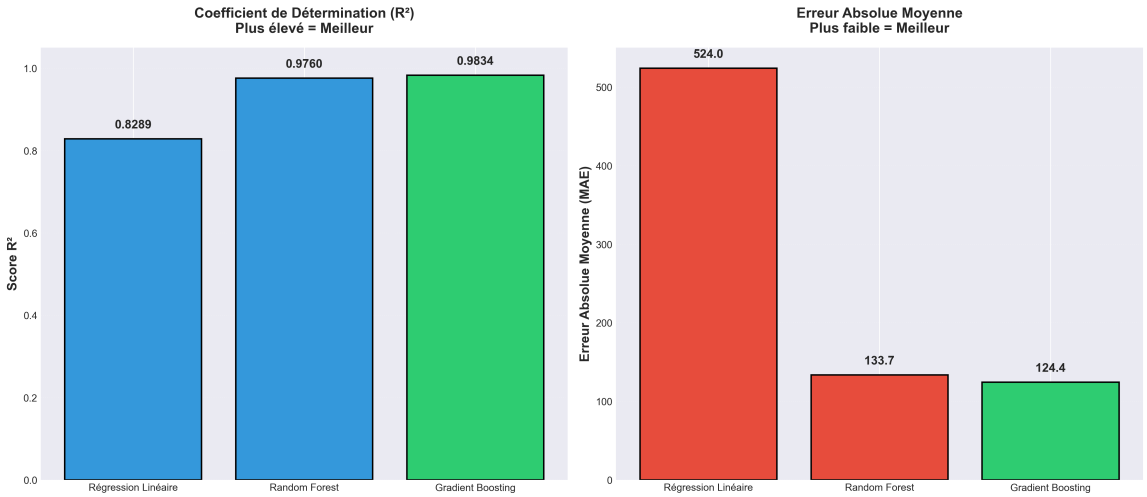

FIGURE 9 – Comparaison des performances des 3 modèles (R^2 et MAE)

Ce graphique compare les 3 modèles sur deux métriques : le R^2 (coefficient de détermination, à gauche) et le MAE (erreur absolue moyenne, à droite). Le R^2 mesure la qualité de la prédiction : plus il est proche de 1, meilleur est le modèle. Le MAE mesure l'erreur moyenne : plus elle est basse, mieux c'est. Le modèle en vert est le meilleur. Le Random Forest et le Gradient Boosting surpassent la régression linéaire, ce qui confirme que la relation est non-linéaire.

Prédictions vs Réalité

Le scatter plot ci-dessous compare les valeurs prédites par le meilleur modèle aux valeurs réellement observées. Chaque point bleu représente un échantillon du jeu de test. L'axe X montre la valeur réelle, l'axe Y la prédiction du modèle. La diagonale rouge représente la prédiction parfaite : plus les points sont proches de cette ligne, meilleur est le modèle.

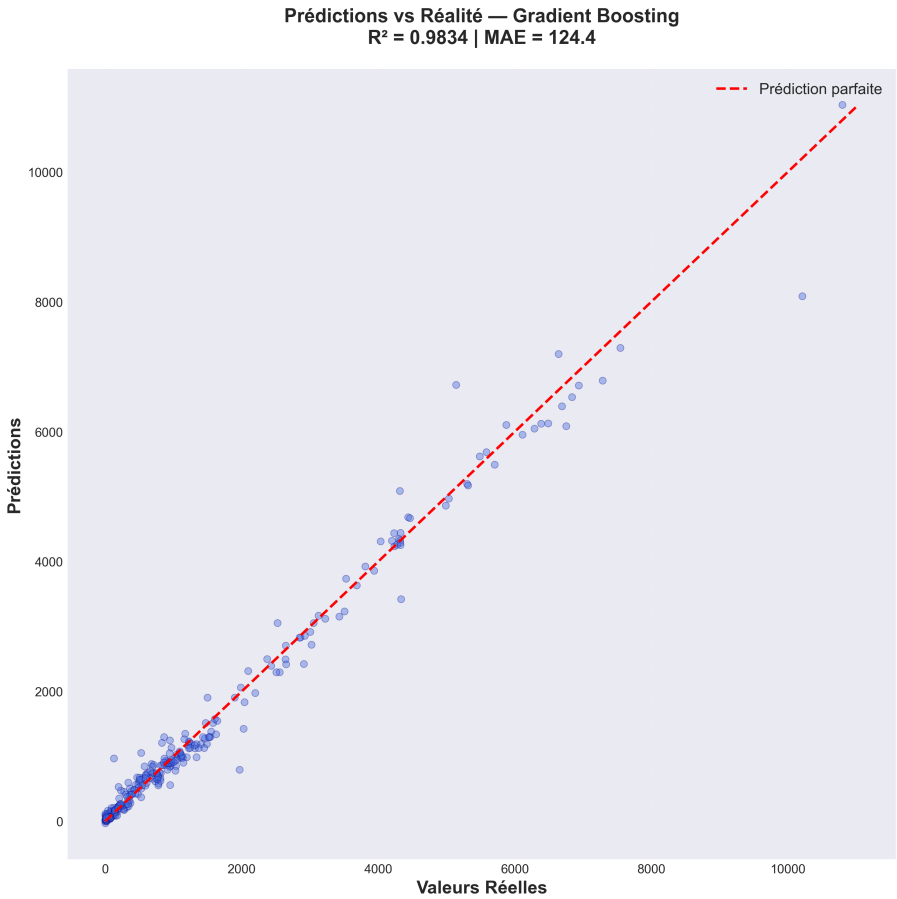

FIGURE 10 – Prédictions vs Valeurs réelles (meilleur modèle)

Importance des Variables

L'analyse de l'importance des features (extraite du Random Forest) permet d'identifier quelles variables ont le plus d'influence sur la prédiction de l'affluence.

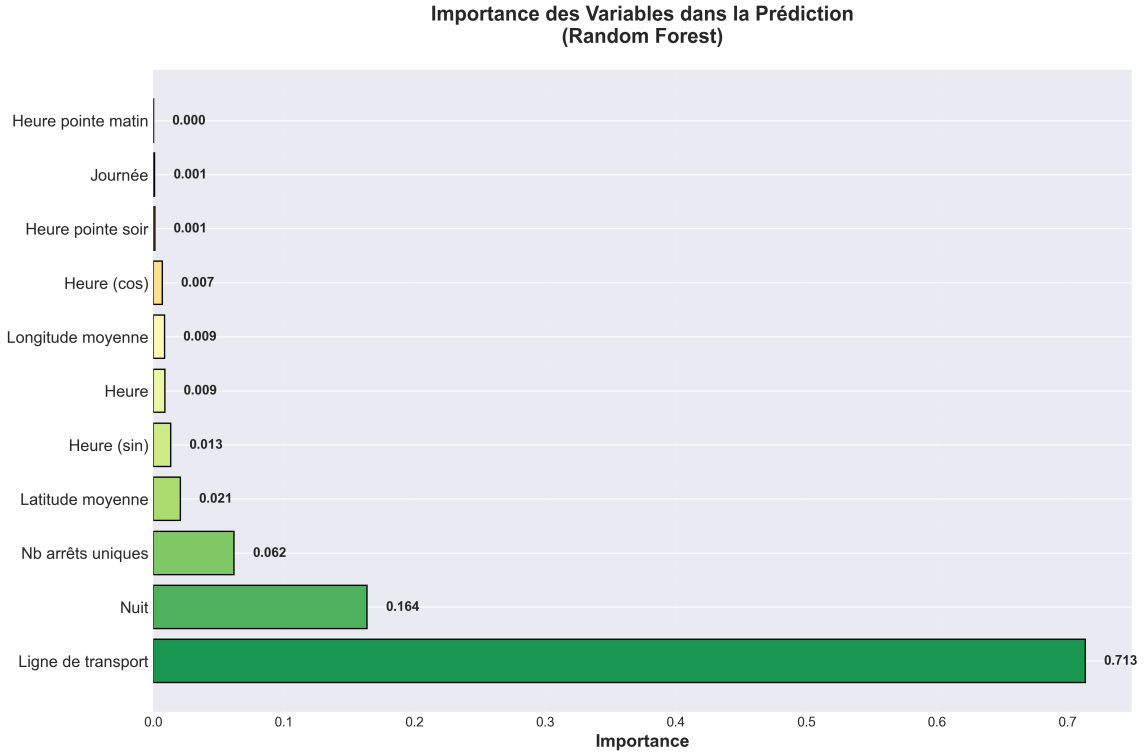

FIGURE 11 – Importance des variables dans la prédiction (Random Forest)

Ce diagramme à barres horizontales montre l'importance relative de chaque variable dans le modèle Random Forest. Plus la barre est longue, plus la variable est déterminante pour la prédiction. L'heure de la journée est le facteur le plus important, suivie par l'encodage de la ligne de transport. Les features cycliques (hour_sin, hour_cos) contribuent également, ce qui valide l'utilisation de l'encodage sinusoïdal pour capturer les patterns périodiques dans les données.

Prédictions Horaires

Le graphique suivant superpose les données observées et les prédictions du modèle pour chaque heure de la journée. Cette comparaison permet de valider que le modèle capture correctement les patterns de rush matinal et du soir.

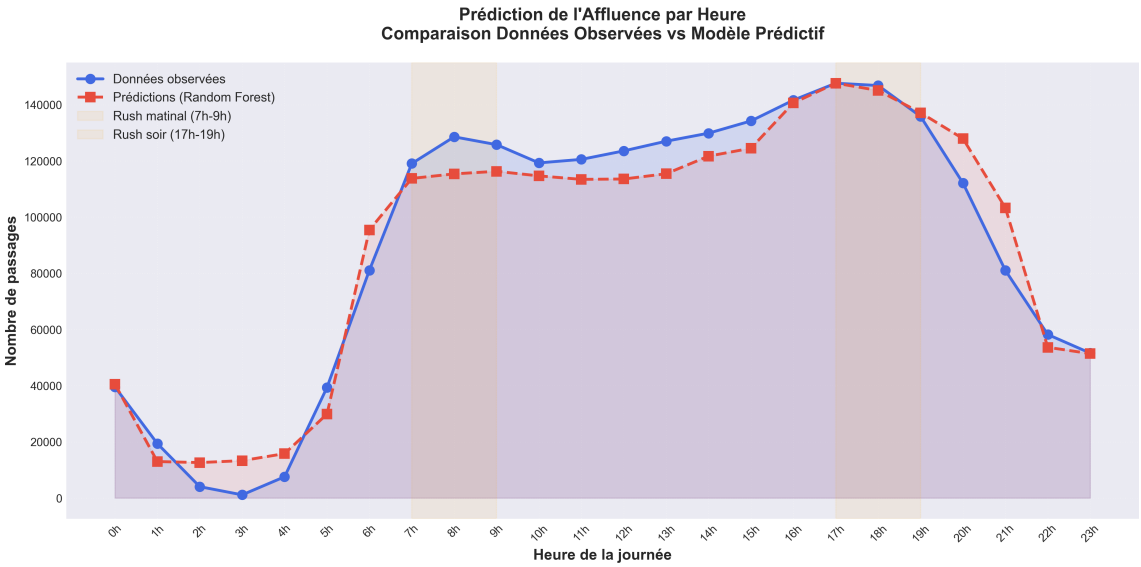

FIGURE 12 – Comparaison données observées vs prédictions par heure

Ce graphique superpose la courbe bleue (données observées) et la courbe rouge en pointillé (prédictions du Random Forest) pour chaque heure de la journée (0h-23h). Les zones orangées transparentes indiquent les périodes de rush. La proximité des deux courbes confirme que le modèle reproduit correctement les patterns de rush matinal et du soir, ainsi que les périodes creuses de nuit.

Recommandations

Sur la base de l'analyse exploratoire et de la modélisation prédictive, les recommandations suivantes sont formulées pour optimiser le réseau de transport de Bordeaux Métropole :

Optimisation Temporelle

Observation : L'heure de pointe (17h) connaît 129.3x plus de passages que l'heure creuse.
Recommandation : Renforcer la fréquence des transports entre 16h et 18h, particulièrement sur les lignes B, 31 et 35.
Impact attendu : Réduction de la surcharge et amélioration du confort des usagers aux heures critiques.

Équilibrage du Réseau

Observation : Forte dispersion de la fréquentation (CV=1.97). Les lignes B, 31, 35 concentrent beaucoup de trafic.
Recommandation : Créer des lignes express parallèles ou augmenter la flotte sur ces lignes principales.
Impact attendu : Meilleure répartition de la charge et temps de trajet réduit pour les usagers.

Amélioration de l'Infrastructure

Observation : L'arrêt « Palais de Justice » est le plus fréquenté (4 516 passages).
Recommandation : Améliorer l'infrastructure aux arrêts les plus fréquentés : abris supplémentaires, affichage temps réel, bancs, accessibilité PMR.
Impact attendu : Meilleure expérience usager et fluidité accrue.

Rationalisation des Arrêts

Observation : 1 014 arrêts (25.6%) sont sous-utilisés.
Recommandation : Évaluer la pertinence de ces arrêts et considérer leur suppression ou fusion avec des arrêts voisins pour optimiser les temps de trajet.
Impact attendu : Réduction des coûts opérationnels et amélioration de la vitesse commerciale.

Limites de l'Analyse

Il est important de noter les limites suivantes de cette analyse, qui doivent être prises en compte dans l'interprétation des résultats :

- Les données GTFS représentent les horaires planifiés, pas la fréquentation réelle
- Pas de données sur le nombre effectif de passagers par trajet
- Pas d'informations sur les retards ou perturbations du service
- L'analyse ne distingue pas les différents jours de la semaine (simulation)
- Pas de données météorologiques ou d'événements spéciaux intégrées
- La modélisation prédictive utilise les passages planifiés comme proxy de l'affluence

Conclusion

Ce projet a permis de réaliser une analyse complète des dynamiques de mobilité urbaine à Bordeaux à partir des données ouvertes GTFS de TBM. Les principaux résultats sont les suivants :

- **Variation temporelle :** La fréquentation varie fortement selon l'heure (ratio 129.3x)
- **Lignes principales :** La ligne B est la plus fréquentée (172 953 passages)
- **Réseau :** 1 014 arrêts sont sous-utilisés
- **Géographie :** De fortes concentrations dans le centre-ville
- **Prédiction :** Le Random Forest capture bien les patterns d'affluence

Les 17 visualisations produites (12 graphiques statiques et 5 tableaux de bord interactifs) permettent d'explorer les données sous différents angles. La modélisation prédictive a démontré que l'heure de la journée et la ligne de transport sont les principaux facteurs déterminants de l'affluence.

Les 4 recommandations formulées (optimisation temporelle, équilibrage du réseau, amélioration de l'infrastructure, rationalisation des arrêts) constituent des pistes concrètes pour améliorer le service de transport de Bordeaux Métropole.

- Étapes du sujet traitées : **7/7** (y compris modélisation prédictive)
- Visualisations générées : **17** (12 PNG + 5 HTML)
- Modèles prédictifs : **3** (Régression Linéaire, Random Forest, Gradient Boosting)
- Recommandations : **4** recommandations argumentées
- Code source : Python documenté et modulaire